

손바닥 sEMG 식별

딥러닝프로그래밍 Step 1 · 딥러닝 비교와 최종 SVM · 차경호

1 문제 정의

문손잡이 회전 중 측정된 sEMG로 등록자 A-E를 구분하는 closed-set 5클래스 식별이다. 동일 분할의 Accuracy·macro F1·연산비용으로 DenseNet161과 두 베이스라인을 비교한다. 학습 데이터만 이용하는 BN 재보정도 별도 평가했다. 최종 선택은 39특징 보정 SVM 단독이며, 재사용 시험창 887/950(93.37%)이다.

2 데이터

공개 CSV 250개(5명×50시행), 시행당 3초·1,000 Hz·2채널이다. 수치가 동일한 E50을 제외한249시행을 사용자별 비율을 유지해 학습 199 / 시험 50으로 먼저 나눴다(seed 42). 창 생성 후 학습 3,781개·시험 950개이며 시험은 사용자별190개다.

원도우	A	B	C	D	E	합계
학습	760	760	760	760	741	3781
시험	190	190	190	190	190	950

3 방법


제공 CSV는 이미 필터링돼 있다. 수업의 60 Hz notch(Q=30)와 4차 20-499 Hz band-pass를 시간축에 추가 적용했다. 각 시행에서300 ms 창·150 ms hop으로19개 창을 만들고 창 전체를 min-max 정규화했다. Morlet(morl) CWT 스케일 1-32의 두 채널 절댓값과 평균으로3×32×300 입력을 만들었다.

300 ms는 짧은 근활성 패턴과 표본 수를 절충한다. 같은 길이로 모델별 입력 시간 범위를 통제했다. 32스케일은 표현 해상도와 연산량을 절충한다. 수업 설정을 고정해 모델 비교의 변환 조건을 통제했다.

SimpleCNN·ResNet18·DenseNet161을 모두 사전학습 없이 Adam(lr=0.001), batch 16, Cross-Entropy, 45epoch로 학습했다. 분할은 고정하고 초기화·서플 seed 42/43/44로3회 반복했으며 마지막45epoch 모델을 평가했다.

SimpleCNN은 3→32→64의 두 합성곱과 평균 pooling, ResNet18은 잔차 연결과 512→5 분류기, DenseNet161은 조밀 연결과 2208→5 분류기를 쓴다. 공통 학습 설정은 수업 예제를 따라 예산을 통제했다. DenseNet의 첫 7×7 합성곱(stride 2)은 torchvision 기본형이며 추가 dropout은 없어 논문 설명과 차이가 남는다.

DenseNet161+BN은 같은 학습 가중치에서 학습 창만1회 순회해 BN 통계를 재계산한 변형이다(batch 16, 서플 seed 2026). 별도 개발검증 40시행에서 Accuracy 88.82→89.08%, F1 88.78→89.04%로 선택했다. 차이는760창 중 순증 2개에 불과하며, 시험 점수와 무관하게 원본과 변형을 모두 보고한다.



제공된 필터 신호의 추가 처리 전후와 학습 창의 CWT 예시다.





4 결과

시험 50시행의 950원도우를 평가했다. 지표는 3회 평균(%)이며 Precision·Recall·F1은 macro 평균이다. 혼동행렬은 seed 42 한 번이며 행=실제, 열=예측, 행 합계=190이다. 빨간 테두리는 최대 오분류다.

모델	Accuracy	Precision	Recall	F1
SimpleCNN	62.63	62.70	62.63	62.08
ResNet18	88.04	88.20	88.04	87.99
DenseNet161	88.53	88.92	88.53	88.55
DenseNet161+BN	88.95	89.31	88.95	88.90

모델	파라미터	학습/BN 초	추론 ms/창
SimpleCNN	19,717	405.6 / 0.0	1.21
ResNet18	11,179,077	1539.6 / 0.0	25.07
DenseNet161	26,483,045	9505.8 / 0.0	65.01
DenseNet161+BN	26,483,045	9505.8 / 79.3	63.65

필수 딥러닝 비교군의 평균 Accuracy 최고는 DenseNet161+BN, 최저는 SimpleCNN이다. 동물은 학습+BN 시간이 짧은 쪽을 우선했다.



4 결과와 최종 선택

39특징 보정 SVM 단독을 최종 모델로 선택했다. 아래 93.37%는 기존에 완료한 단일 모델의 재사용 시험 결과이며, 이번 제출 정리에서 새 학습이나 SVM 튜닝을 수행한 수치가 아니다. 필수 DenseNet161·ResNet18·SimpleCNN 비교와 BN 변형은 앞뒤 페이지에 유지했다.


SVM 방법

같은 199/50 시행 분할과 300 ms 창·150 ms hop을 쓴다. 전체 시행에 notch·band-pass를 적용한 뒤 창별 채널 평균을 제거한다. CWT·min-max 대신 로그 RMS·MAV 4개와 상대 대역파워·주파수·엔트로피·파형 모양·채널 상관 35개를 결합한다. 학습 부분에서만 StandardScaler를 적합하고 RBF SVC(C=1, gamma=scale)를 학습한다.

Sigmoid 확률 보정은 seed 2026의 시행 단위 3-fold OOF 점수로 수행한다(ensemble=False). 각 보정 fold 안에서 scaler와 SVC를 새로 적합하고, 마지막에는 199 개발시행 전체로 단일 SVC를 재적합한다. 기존 18개 조합 탐색 뒤 고정한 보정 후보이며, 아래 5-fold는 선택 후 개발 안정성 점검이다.

최종 모델	Accuracy	Precision	Recall	F1
보정 SVM 단독	93.37	93.45	93.37	93.40

887/950 시험창 정답; Precision-Recall-F1은 macro %. 50시행에서 19창의 확률을 평균한 별도 지표는 50/50이다. 950창은 독립 표본이 아니며, 3초 시행 집계 100%를 300 ms 창 정확도와 혼동하지 않는다. 앞쪽 딥러닝 표는 3seed 평균이므로 단일 SVM과 반복 수·실행 조건이 다르다.



행=실제, 열=예측. 최대 오분류 E→B 14개를 빨간색으로 표시했다(B→E 13개). 두 사용자 사이에 27/63개 오류가 집중됐다. 진폭 정보를 유지한 특징은 구분에 도움이 될 수 있으나 세션·전극 조건에 민감할 수 있으며, 이것만으로 오류 원인을 확정하지 않는다.

개발 Fold	1	2	3	4	5	평균±SD
Accuracy %	93.82	89.87	93.03	93.03	91.36	92.22±1.42
Macro F1 %	93.81	89.89	93.03	93.01	91.12	92.17±1.45

SD는 모집단 기준(ddof=0). Fold별 시험창 수는 760/760/760/760/741이며, 이 값은 독립시험 또는 중첩 모델선택 CV가 아니다.

39특징·1,440 support vectors·저장 모델 642,444 bytes; 최종 개발 적합 0.751초(3개 보정용 적합+전체 재적합). 기존 모델-only 추론은 0.818 ms/창으로 특징 추출·기록 시간을 제외한다. 다른 실행 조건의 딥러닝 시간과 직접적인 속도비를 주장하지 않는다.

최종 선택 이유는 단일 SVM의 성능과 간단한 추론 구성을 함께 고려했기 때문이다. 전처리의 filtfilt는 시행 전체를 사용하는 비인과 처리이므로 실시간 300 ms 응답 성능을 검증한 것은 아니다. 저장 예측·개발 OOF·고정 재현 코드와 점검 방법은 svm_final/에 있다.

4 결과 교차검증

최종 시험 50시행을 제외한199 개발시험 내부에서 stratified5-fold를 수행했다. 각 fold는 새 DenseNet을45epoch 학습했으며 seed 43-47이다. 아래는 원본 / BN 변형이고 SD는 모집단 표준편차다.

Fold	검증 시행	Accuracy % 원본 / BN	Macro F1 % 원본 / BN
1	40	76.18 / 84.34	76.41 / 84.39
2	40	77.89 / 85.39	77.97 / 85.47
3	40	85.79 / 86.18	85.72 / 86.17
4	40	81.05 / 85.53	81.22 / 85.56
5	39	85.43 / 86.64	84.94 / 85.98
평균±SD	199 전체	81.27±3.87 / 85.62±0.78	81.25±3.68 / 85.51±0.62

논문(Accuracy 94.00%, F1 93.99%, CV Accuracy/F1 91.66/91.64%)과 원본 DenseNet의 관측 차이는 각각 -5.47, -5.44, -10.39, -10.39%p였다. 본 실험의 중복 제거·시행 분할·개발 CV·수업 구현·재사용 시험 조건에서 얻은 차이이며, 특정 원인이나 구조의 우열로 단정하지 않았다.

5 오류 분석

SimpleCNN: 최대 오류 B→C 52개, 반대 C→B 35개였다. C 예측 256개(실제190개)이며, 예시 B/b (47).csv의 0.15-0.45초를 오분류했다.

ResNet18: 최대 오류 E→B 23개, 반대 B→E 6개였다. B 예측 201개(실제190개)이며, 예시 E/e (17).csv의 0.00-0.30초를 오분류했다.

DenseNet161: 최대 오류 E→B 29개, 반대 B→E 13개였다. B 예측 227개(실제190개)이며, 예시 E/e (17).csv의 0.00-0.30초를 오분류했다.

DenseNet161+BN: 최대 오류 E→B 33개, 반대 B→E 6개였다. B 예측 226개(실제190개)이며, 예시 E/e (17).csv의 0.00-0.30초를 오분류했다.

창별 min-max는 각 창 의 공통 절대 진폭·오프셋을 제거한다. 이 때문에 비슷한 시간-스케일 모양을 구분하기 어려워지고, 겹치는 창에서 같은 오분류가 반복됐을 가능성이 있다. 이는 전처리 구조에 근거한 가설이며 실제 원인을 확정한 것은 아니다.

6 한계

1) 5명·단일 세션·실험실 동작 자료다. 미등록자 거절과 다른 날짜·전국 재부착·손잡이 환경은 검증하지 않았다.

2) 같은 시험의 19개 창은 겹치므로950개를 독립 시험으로 볼 수 없다. 최종 50시행은 이전5epoch 결과를 본 뒤 재사용했으므로 탐색적 비교이며 새로운 독립시험이 아니다.

3) 논문의 정확한 분할·CWT·dropout·첫 합성곱 변경 세부가 모두 명시돼 있지 않아94%와 직접적인 우열을 주장하지 않는다. BN 선택과 CV도 같은 개발집합을 사용했으므로 작은 개선의 일반성을 입증하지 않는다.

7 재현 정보

딥러닝 재현 환경: Linux, Python 3.12.14, PyTorch 2.8.0+cpu, torchvision 0.23.0+cpu를 사용했다(전체 의존성은 requirements.txt). AMD EPYC의 논리 CPU 4개씩 두 작업을 병렬 학습했으며 BN 변형은 원본 학습을 공유한다. 학습시간은 보존된 epoch의 학습 루프만 포함하며 전처리·검증·중단 후 폐기된 계산은 제외한다. 추론은 학습 종료 후 같은 논리 CPU 4개에서 batch 1, 10회 예열 뒤 100회 평균이며 전처리를 제외한다.

SVM 재현 환경: Python 3.12, NumPy 2.3.5, SciPy 1.17.0, scikit-learn 1.8.0, joblib 1.5.3이며 CPU로 실행한다. 보정 fold seed는 2026이다. 고정 코드·라이브러리 버전·저장 예측 검산과 재실행 명령은 svm_final/README.md에 있다.

설치·실행·파일 역할은 README에 있다. frozen_plan.json은 45epoch 최종 평가 전에 고정한 계획, runs/는 설정·loss·복구 기록, evaluation/은 실제 예측, summary/는 재검산된 지표·그림·보고서다.

제출 저장소: <https://github.com/KyunghoCha/semg-auth-coursework> · 최종 코드·결과: sEMG_final/

자료: sea3551/palm-sEMG-doorknob-filtered, commit adb7955f4416165c88e4111af6f8fdafd416209c, Data © 2025 Yeonjung Shin, CC BY 4.0. 논문 DOI 10.1038/s41598-026-46294-3. 방법과 베이스라인은 Step 1 2·3주차 강의 예제 기반이다.

생성형 AI 사용: 코드 작성·실험 실행·검증·보고서 정리에 활용했다. 수치는 저장한 실제 예측에서 계산했다.